

ICG Final Project Report

Beautifying Images - Photo Ranking

R14922115 胡烜彰

R14944050 莊鈞傑

1. 前言

近年來，智慧型手機的普及使一般使用者能輕易在短時間內拍攝大量照片。然而，拍得多並不等於選得好，使用者經常面對的問題是：在連拍或同一場景拍下的多張候選照片中，究竟哪一張最值得保留？這個從少量候選中挑選最佳的需求，與傳統影像美學評估文獻中常見的「給單張照片打分數」有微妙但關鍵的差異：使用者並不在乎模型給出高或低的分數，他們只在乎最終是否挑對了那一張。

基於這個現象，我們提出一個以排序為核心目標的評估系統。我們使用 AADB (Aesthetic and Attributes DataBase) 資料集訓練模型，並設計了一個結合 score regression、attribute prediction、pairwise ranking 與 listwise ranking 的多目標 loss function，使模型同時具備「分數準」與「排序對」兩種能力。在推論階段，系統可接受 2 到 5 張候選照片作為輸入，輸出排序結果與 11 個 attributes 的分析，並透過 LLM 生成自然語言解釋，告訴使用者為什麼這張比較好。

本報告的主要貢獻可歸納為：

- (1) 提出以 Top-1 Accuracy 為主要指標的訓練與評估流程，更貼近實際應用情境；
- (2) 設計多目標 loss function，並透過 v1 / v2 / v3 三版設定的對照實驗，驗證 loss 權重平衡的重要性；
- (3) 整合 Cohen-Or 色彩和諧理論作為解釋的補充資訊，並透過 ablation 實驗驗證其角色；
- (4) 結合本地 LLM (Qwen3.5-9B-GGUF) 生成自然語言評論，使系統不只給分，還能解釋。
- (5) 提供基於 Gradio 的互動式 Web UI，使系統能以上傳的方式，立即提供排序、attribute 比較與文字解釋，無需操作命令列。

2. Related Work

2.1 影像美學評估

影像美學評估是電腦視覺領域長期關注的問題。早期研究多採用人工設計的特徵搭配傳統機器學習模型。隨著深度學習興起，CNN 模型成為主流，AVA、AADB 等大型美學標註資料集的釋出，使模型能直接從資料中學習人類的美感偏好。其中，AADB 資料集 [4] 除了提供整體美學分數，還額外標註了 11 個視覺 attributes (包含 Balancing elements、Color harmony、Content、DoF、Light、Motion blur、Object emphasis、Repetition、Rule of thirds、Symmetry、Vivid color)，使模型能透過多任務學習同時預測分數與屬性，本專案亦採用此資料集。

2.2 排序導向的影像評估

傳統影像品質與美學評估方法多將任務建模為絕對分數的回歸問題，目標是讓模型輸出貼近人類給出的 Mean Opinion Score (MOS)。然而 Xu et al. [2] 指出，人類在主觀測試中其實難以精確評定影像品質的微小差異，導致 MOS 標註本身存在不可靠性；相對地，人類對於兩張影像進行 pairwise comparison 的判斷則穩定許多。因此提出 PRLIQM (Pairwise Rank Learning based Image Quality Metric)，將品質評估任務轉化為 pairwise ranking 學習問題，並依據真實分數差距為 pair 加權，使大差距的 pair 在訓練中貢獻更大。

本專案延續此一思路：考量到我們從候選照片中挑選最佳，本質上是排序任務，因此將 pairwise ranking loss 納入訓練目標，並進一步加入 listwise ranking loss 以強化全局排序信號。

2.3 色彩和諧理論

色彩和諧是色彩學中用以描述色彩搭配是否令人感到愉悅的概念。Matsuda 將色相環上的和諧色彩歸納為八種幾何模板，每種模板定義了和諧色相應落在哪些區段。Cohen-Or et al. [1] 在 SIGGRAPH 2006 進一步將此理論工程化：給定一張照片，演算法將每個像素轉換到 HSV 空間，以飽和度為權重建立色相直方圖，再對八種模板逐一旋轉比對，找出與該圖最接近的模板與旋轉角度。距離越小，代表照片的色彩越和諧。

該論文原意是用於「重新著色 (recoloring)」將不在模板內的色相平移回模板內，以提升圖像和諧度。本專案僅借用其第一階段（分析），不修改照片，而是

將算出的和諧距離轉換為 score / level / percentile 三種特徵，作為 LLM 解釋時的補充資訊。色彩和諧是否應該影響排名，我們在第 4 節透過 ablation 實驗驗證。

3. 方法

3.1 模型架構

本系統以 ConvNeXt-Small [3] 作為視覺特徵抽取的 backbone，並使用 ImageNet 預訓練權重以加速收斂。我們將 ConvNeXt 原本的分類層替換為 Identity，使其輸出 768 維的視覺特徵向量 $f \in \mathbb{R}^{768}$ 。

在 backbone 之上，我們設計兩個平行的預測 head:

- Score Head：兩層全連接網路 ($768 \rightarrow 512 \rightarrow 1$)，搭配 ReLU 與 Dropout，最後經 Sigmoid 函數壓縮至 $[0, 1]$ 區間，輸出單一的美學分數。
- Attribute Head：結構與 Score Head 相同，但最後輸出維度為 11，並經 Tanh 函數壓縮至 $[-1, 1]$ 區間，分別對應 AADB 的 11 個視覺 attributes。

雙頭結構的設計動機是：雖然最終任務只需要美學分數，但讓 backbone 同時學習預測 11 個語意明確的視覺屬性（如構圖平衡、光線、色彩和諧等），可作為一種特徵正規化 (feature regularization)，迫使 backbone 學到「與美學相關的、可解釋的」視覺概念，而非僅記憶分數。這種多任務學習 (multi-task learning) 的設計，在後續的 LLM 解釋階段也提供了豐富的屬性資訊作為描述依據。

3.2 Loss Function

考量到是從候選照片中挑選最佳，本專案的訓練目標不能只關注分數的絕對值，更必須確保模型輸出的相對排序正確。因此，我們設計了一個由四種 loss 加權組合而成的多目標 loss function:

$$L_{\text{total}} = L_{\text{score}} + \lambda_{\text{attr}} \cdot L_{\text{attr}} + \lambda_{\text{rank}} \cdot L_{\text{pairwise}} + \lambda_{\text{list}} \cdot L_{\text{listwise}}$$

四種 loss 的角色分別說明如下:

- (1) Score Loss (L_{score}): 使用 Smooth L1 Loss 對美學分數進行回歸，提供最基本的數值監督信號，使預測分數不偏離真實值太遠。Smooth L1 相對於 MSE

對 outlier 更為穩健。

(2) Attribute Loss (L_{attr})：11 個屬性的 MSE Loss，作為輔助任務。權重 λ_{attr} 設為較小的數值，避免輔助任務的梯度蓋過主任務。

(3) Pairwise Ranking Loss (L_{pairwise})：對同一 batch 內所有真實分差超過 min_{diff} 的影像對 (i, j) ，要求模型預測分差的方向與真實分差一致：

$$L_{\text{pairwise}} = \text{mean}(\log(1 + \exp^{(-\text{sign}(y_i - y_j) \cdot (\hat{y}_i - \hat{y}_j - \text{margin}) / T))})$$

其中 y 為真實分數、 $\hat{y}$ 為預測分數、 T 為 temperature 參數。此外，我們參考 Xu et al. [2] 的做法，依真實分差大小為 pair 加權 ($\text{rank_weight_by_diff}$)，使分差大的 pair 在訓練中貢獻更多，這是本 loss 對於排序能力的核心貢獻。

(4) Listwise Ranking Loss (L_{listwise})：將整個 batch 的真實與預測分數透過 softmax 轉換為機率分布，並以 KL 散度衡量兩者差異：

$$L_{\text{listwise}} = \text{KL}(\text{softmax}(y / T) \parallel \text{softmax}(\hat{y} / T))$$

Pairwise loss 著眼於兩兩比較的局部排序，而 listwise loss 則對齊整批分數的全局分布形狀，兩者互補。

四個 loss 的權重組合是本專案的關鍵設計選擇。我們在第 4 節透過 $v1 / v2 / v3$ 三版設定的對照實驗，驗證了權重平衡對最終排序表現的影響。

3.3 訓練策略

為了在小型資料集（AADB 約一萬張）上有效訓練深度模型，我們採用以下訓練技巧：

- Backbone freezing：訓練前 2 個 epoch 凍結 backbone，僅訓練兩個 head，避免預訓練特徵在尚未對齊的 head 上被破壞。
- Layer-wise learning rate：Head 的學習率為 backbone 的 10 倍，使 head 能快速適應任務，同時 backbone 進行細微調整。
- EMA (Exponential Moving Average)：以 $\text{decay} = 0.999$ 維護模型權重的指數移動平均，最終存檔的是 EMA 模型而非當前模型，使推論結果更穩定。
- Tail-balanced sampling：分數極低 (< 0.35) 或極高 (> 0.70) 的樣本以兩倍權重取樣，避免模型在分數的邊界區段表現不佳。
- Cosine LR schedule with warmup：前 3 個 epoch 線性升溫，之後以 cosine 退至最低學習率，是當前 CV 任務的標準作法。
- Test-Time Augmentation (TTA)：推論時對輸入影像進行五點裁切（中心 +

四角) 並各自加入水平翻轉, 共最多 10 個 view, 將各 view 的分數平均後輸出。TTA 在排序任務中尤其有效, 可顯著降低單一裁切造成的隨機波動。

模型選擇的依據為驗證集上的 Top-1 Accuracy, 而非傳統的 Spearman 或 MSE。這個選擇進一步將排序導向貫穿到整個訓練流程, 而非僅止於 loss 設計。

3.4 色彩和諧分析與 LLM 解釋

除了深度學習模型的預測, 本系統還整合了基於 Cohen-Or 色彩和諧理論 [1] 的色彩分析模組。流程如下:

1. 將輸入圖像由 RGB 轉換至 HSV 色彩空間。
2. 過濾飽和度過低 ($S < 25$) 或亮度過低/過高 ($V < 30$ 或 $V > 240$) 的像素, 避免灰階與極端像素影響色相統計。
3. 以飽和度為權重, 建立 360 bin 的色相直方圖。鮮豔的像素對和諧度判斷的貢獻較大。
4. 對 8 種色相模板 (i, V, L, I, T, Y, X, N) 與 0° - 358° 共 180 個旋轉角度逐一計算加權色相距離, 取最小者作為該圖的最佳和諧詮釋。距離越小代表色彩越和諧。
5. 將最小距離正規化後轉換為 harmony_score、harmony_level (low / mid / high) 與 harmony_percentile (在訓練集分佈中的百分位) 三種輸出。

色彩和諧資訊不直接影響模型的排序結果 (見 4.4 節 ablation 實驗), 而是在 LLM 解釋階段作為補充資訊使用。

LLM 解釋生成流程。本系統的 rank.py 在輸出排序結果的同時, 會將每張照片的美學分數、11 個 attributes 分數、色彩和諧資訊整理成一份結構化的 JSON。explain.py 將此 JSON 連同預先設計的 system prompt 輸入到本地 LLM (Qwen3.5-9B-GGUF, Q4_K_M), 由 LLM 生成自然語言評論。

為避免 LLM 編造模型未計算的內容, 我們在 system prompt 中明確要求:

- (a) 排序結果僅由 aesthetic_score 決定, 色彩和諧不可被描述為排序原因;
- (b) 只能引用 JSON 中存在的數據, 不可臆測畫面內容;
- (c) 若分數差距小, 需誠實標示為接近的情況。此設計使 LLM 的輸出能保持與模型一致, 避免幻覺問題。

4. 實驗與結果

4.1 資料集

本專案使用 AADB (Aesthetic and Attributes DataBase) [4] 作為訓練與評估資料。AADB 共包含約 10,000 張取自 Flickr 的真實照片，每張由多位標註者給出 $[0, 1]$ 區間的美學分數，並標註 11 個視覺 attributes (範圍 $[-1, 1]$)。資料集預先切分為 train (8458)、validation (500)、test (1000) 三個子集，本報告所有實驗結果均在 test set 上評估。

4.2 評估指標

由於本專案以從候選照片中挑選最佳為核心應用，傳統的回歸指標（如 MSE、Pearson）並無法完全反映系統在實際情境中的表現。因此我們同時報告兩類指標。

(1) 回歸指標。為衡量預測分數與真實分數的整體相關性，我們採用三種常見指標: Pearson、Spearman 與 Kendall。

- Spearman 等級相關係數定義為：

$$\rho = 1 - 6 \cdot \sum d_i^2 / (n \cdot (n^2 - 1))$$

其中 d_i 為第 i 個樣本在預測排名與真實排名中的差， n 為樣本數。

Spearman 衡量兩組排名的單調相關性，不受實際分數的線性尺度影響，特別適合排序任務的評估。

- Kendall τ 係數則計算所有樣本對中順序一致與順序顛倒的比例差：

$$\tau = (C - D) / (n \cdot (n - 1) / 2)$$

其中 C 為順序一致的 pair 數、 D 為順序顛倒的 pair 數。Kendall τ 比 Spearman 更嚴格，數值通常較小，但更直觀地反映兩兩排序正確的比例。

- Pearson 相關係數則衡量預測值與真實值之間的線性關係，可作為輔助參考但不適合單獨作為排序能力的指標。

(2) 分組排名指標。為更貼近實際應用情境，我們設計分組評估流程: 從 test set 中隨機抽取 5 張一組，重複 5000 次，計算下列指標:

- Pairwise Accuracy：組內所有兩兩 pair 中排序正確的比例。
- Top-1 Accuracy：模型選出的最高分照片是否真的是該組中真實分數最高的那張。此指標直接對應應用情境，是本專案最重視的指標。

- Group Spearman / Group Kendall：組內排名的 Spearman 與 Kendall 係數平均值。

4.3 主要結果

我們訓練了三個版本的模型作為對照：

- v1 (baseline)：採用初始 loss 權重設定， $\lambda_{\text{rank}} = 0.50$ ， $\lambda_{\text{list}} = 0.15$ ， $\lambda_{\text{attr}} = 0.05$;
- v2 (激進調整)：大幅提升排序相關 loss 的權重， $\lambda_{\text{rank}} = 0.70$ ， $\lambda_{\text{list}} = 0.25$ ，並縮小 rank_min_diff、調整 backbone 的可訓練範圍;
- v3 (保守調整)：在 v1 基礎上小幅強化排序信號， $\lambda_{\text{rank}} = 0.55$ ， $\lambda_{\text{list}} = 0.18$ ，其餘設定大致維持。

Metric	Old	New	Delta
MSE ↓	0.0200	0.0199	-0.0001 ✓
MAE ↓	0.1095	0.1095	+0.0001
Pearson ↑	0.6736	0.6786	+0.0050 ✓
Spearman ↑	0.6647	0.6660	+0.0013 ✓
Kendall ↑	0.4977	0.4997	+0.0020 ✓
Attr MAE ↓	0.1758	0.1762	+0.0003
Group Spearman ↑	0.5601	0.5681	+0.0080 ✓
Group Kendall ↑	0.4766	0.4836	+0.0069 ✓
Pairwise Acc ↑	0.7459	0.7496	+0.0037 ✓
Top-1 Acc ↑	0.6050	0.6050	+0.0000
Rank Score ↑	0.6755	0.6773	+0.0018 ✓

從 v1 vs v3 的比較中可以看出，v3 在多項指標上均有小幅提升，包括 Top-1 Accuracy 與 Pairwise Accuracy 等核心排序指標。這驗證了在 v1 設定接近最佳的前提下，溫和地強化排序信號能進一步改善排名表現這項假設。

然而，v2 的對照實驗則呈現截然相反的結果：當我們將 ranking loss 權重從 0.50 拉高至 0.70 時，模型在所有指標上均出現微幅退化。這個負面結果反而表明 loss 權重並非越高越好，過度強調排序會破壞分數本身的數值意義，反而傷害模型的整體表現。因此，多目標 loss function 需要的是精細平衡而非最大化單一信號。

v1 → v3 的改進雖然數值上不大，但具有方向性：每一項主要指標均呈現一致的提升，而非隨機波動。這暗示 v3 的權重設定確實是一個更合理的局部最佳解。

4.4 色彩和諧 ablation 實驗

為驗證色彩和諧是否應該影響排序，我們在 test set 上比較三種策略：

- 策略 A：僅用美學分數排序 (baseline);
- 策略 B：僅用 color_harmony.py 的和諧分數排序;
- 策略 C：兩者線性組合， $\text{final_score} = \text{aesthetic_score} + \alpha \cdot \text{harmony_score}$ ， $\alpha \in \{0.02, 0.05, 0.1, 0.2, 0.5\}$ 。

```
aesthetic_only      -> pairwise=0.7459  top1=0.6050
harmony_only        -> pairwise=0.5058  top1=0.2340
combined alpha=0.0   -> pairwise=0.7459  top1=0.6050  (Δ top1=+0.0000)
combined alpha=0.02  -> pairwise=0.7459  top1=0.6040  (Δ top1=-0.0010)
combined alpha=0.05  -> pairwise=0.7457  top1=0.6020  (Δ top1=-0.0030)
combined alpha=0.1    -> pairwise=0.7453  top1=0.6010  (Δ top1=-0.0040)
combined alpha=0.2    -> pairwise=0.7449  top1=0.5980  (Δ top1=-0.0070)
combined alpha=0.5    -> pairwise=0.7419  top1=0.5850  (Δ top1=-0.0200)
```

```
Pearson(true_score, harmony_score) = 0.0370  p=2.4251e-01
```

結果有三點：

1. 色彩和諧單獨幾乎無法排序：策略 B 的 Top-1 Accuracy 僅 23.4%，接近隨機猜測 (20%)。
2. 加入色彩和諧反而影響排序：策略 C 中 α 越大表現越差，從 60.5% 單調下降至 58.5%，無任何 α 值能超越 baseline。
3. 真實美學分數與色彩和諧分數的 Pearson 相關係數僅 $r = 0.037$ ($p = 0.24$)，統計上不顯著。

實驗顯示色彩和諧捕捉的是色彩搭配的數學規律，而非人類主觀美感和諧的純色天空可能平庸，色彩衝突的街頭攝影卻可能極具張力。因此我們將色彩和諧定位為 LLM 解釋時的補充資訊，而非排序依據。

4.5 範例展示

除了命令列流程，我們也以 Gradio Web 介面展示同一組照片的完整使用流程。只需透過瀏覽器上傳照片，即可同時看到縮圖排序、attribute 比較表與文字解釋。

Web UI 與命令列流程使用同一個 checkpoint 與同一套 rank.py 邏輯，差別僅在於前端呈現方式與解釋生成的後端選擇。這也使本專案的成果不僅是一個研究原型，更接近一個可實際使用的應用程式。LLM 的評論結構符合 system prompt 的設計：先給出一句總結性判斷，接著逐張分析優缺點，最後比較兩張

的差異。值得注意的是，LLM 並未提及色彩和諧作為決定排名的原因，而是將其作為描述的補充這正是本專案 prompt 設計的目標。

ICG Photo Ranking

Upload 2-5 photos. The model selects the strongest image and explains the ranking with aesthetic attributes and color harmony.

Drag images into the upload area for automatic upload, or use the upload button.

Upload 2-5 Images

拖放檔案至此處
- 或 -
點擊上傳

Drag 2-5 images into the upload area, or use the upload button.

Rank Photos

Selected Photo

Rank 1

Ranking Results



Rank 1: **imgA.jpg**
Ranking score 0.704



Rank 2: **imgB.jpg**
Ranking score 0.653

Rank	Image	Ranking score	Color harmony fit	Template	Top attributes
1	imgA.jpg	0.704	high (0.24 deg, 52.1 pct)	X	Content=0.82, Color harmony=0.30, Rule of thirds=0.27
2	imgB.jpg	0.653	medium (0.32 deg, 46.9 pct)	X	Content=0.82, Repetition=0.28, Vivid color=0.23

Explanation

Why **imgA.jpg** was selected

imgA.jpg is selected because its predicted aesthetic ranking is strongest in this set. It is ahead of **imgB.jpg** by **0.050** (moderate margin). Compared with the other candidates, it looks stronger because:

- the main subject is clearly easier to identify.
- the focus separation and depth of field are slightly more appealing.
- the colors appear slightly more coordinated. Its color-harmony fit is **high** by template distance (**0.24 deg**, 52.1 percentile), closest to template **X**.

5. 討論與限制

5.1 從實驗中學到的設計原則

v1 → v2 → v3 的迭代過程得知：多目標 loss function 的關鍵不在於找出最強的單一信號，而在於維持信號間的平衡。v2 大幅提升 pairwise 與 listwise loss 權重後，分數的數值意義被削弱，所有指標反而下降；v3 改採溫和強化才帶來實質提升。

色彩和諧 ablation 也有類似啟示：並非所有直覺上合理的特徵都適合作為排序依據。色彩和諧理論扎實、計算明確，但它捕捉的是數學規律而非主觀美感。將其定位為解釋的補充資訊，而非排序的依據，是基於實驗證據的設計取捨。

5.2 限制

本專案仍有以下幾項限制，值得在未來改進：

1. 資料集偏差：AADB 影像來源以 Flickr 為主，標註者偏好難免有偏差。在不同風格上，模型表現可能與 test set 數字有落差。
2. Top-1 Accuracy 上限：5 張一組的設定下約為 60%，雖遠優於隨機 (20%)，但仍有空間。值得注意的是，由於美感本身具主觀性，由人類標註間的一致性也僅約 70%，本專案已接近此上限。
3. LLM 解釋的可控性：模型偶爾有過度強調單一屬性 (如 Object emphasis) 的傾向，加入 prompt 限制後狀況改善但仍非完全可控。
4. 推論效率：ConvNeXt-Small 搭配 10-view TTA 在 CPU 上推論需數秒；Qwen3.5-9B Q4_K_M 在無 GPU 加速下生成解釋約需 30 秒至 1 分鐘，距離即時應用仍有優化空間。

6. 結論

本專案針對從多張候選照片中，挑選最佳這項實際需求，建立了一個排序導向的照片美學評估系統。我們在 AADB 資料集上訓練了基於 ConvNeXt-Small 的雙頭模型，並設計結合 score regression、attribute prediction、pairwise ranking 與 listwise ranking 的多目標 loss function，使模型同時具備「分數準」與「排序對」兩種能力。系統在 test set 上達成 Top-1 Accuracy 60% 以上，已接近由人類標註間的一致性水準。

除了模型本身，本專案亦完成了完整的應用流程：rank.py 接收 2 至 5 張候選照片，輸出排序、屬性分析與色彩和諧資訊；explain.py 將結構化結果輸入本地 LLM 生成自然語言解釋。我們亦透過 v1 / v2 / v3 三版對照實驗與色彩和諧 ablation，驗證了多目標 loss 需要平衡而非極端化、以及色彩和諧不適合作為排序依據等設計選擇。這些實驗結果或為未來相關研究提供參考。

參考文獻

- [1] Cohen-Or, D., Sorkine, O., Gal, R., Leyvand, T., & Xu, Y. Q. (2006). Color harmonization. *ACM Transactions on Graphics (SIGGRAPH)*, 25(3), 624–630.
- [2] Xu, L., Li, J., Lin, W., Zhang, Y., Zhang, Y., & Yan, Y. (2016). Pairwise comparison and rank learning for image quality assessment. *Displays*, 44, 21–26.
- [3] Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 11976–11986.
- [4] Kong, S., Shen, X., Lin, Z., Mech, R., & Fowlkes, C. (2016). Photo Aesthetics Ranking Network with Attributes and Content Adaptation. In *European Conference on Computer Vision (ECCV)*, 662–679. GitHub: <https://github.com/aimerykong/deepImageAestheticsAnalysis>